

Traitement du langage naturel

Sac de mots, normalisation, plagiat et analyse de sentiment

Traduit et adapté depuis Bootstrap World (Fall 2026)

Adapté au contexte francophone — textes, stop words et normalisation en français

Licence Creative Commons 4.0 International

*Ces supports ont été développés en partie grâce au soutien de la National Science Foundation
(bourses 1042210, 1535276, 1648684, 1738598, 2031479 et 1501927).*

Table des matières

1	Tracer des essais dans l'espace	3
1.1	Lancement	3
1.2	Exploration : attributs quantitatifs du texte	6
1.3	Synthèse	9
2	Normalisation des données	10
2.1	Lancement	10
2.2	Exploration : trois fonctions de normalisation	11
2.3	Synthèse	14
3	Similarité supervisée et non supervisée du langage	15
3.1	Lancement	15
3.2	Exploration : détecter le plagiat	16
3.3	Synthèse : éthique des détecteurs de plagiat	17

Tracer des essais dans l'espace

Objectif de la section

Les élèves révisent leur progression du tracé de données numériques au tracé de données d'images, puis considèrent le défi de tracer du texte écrit par des humains. Ils appliquent le modèle sac de mots de *Construire des centroïdes*, et confrontent les défis supplémentaires que le langage naturel présente.

Lancement

Aujourd'hui, nous allons explorer comment les modèles d'apprentissage automatique travaillent avec le langage naturel — les langues que les humains utilisent — en commençant par des textes écrits en français.

Rappelons notre discussion sur la similarité.

Point clé

Nous pouvons **tracer des documents dans l'espace** et utiliser la **géométrie** pour calculer une notion de « proximité ».




FIGURE 1 – Système de coordonnées 3D avec des points orange représentant le prix vs. la qualité des frites vs. la qualité des burgers. Un point vert représente In-N-Out, avec des lignes tracées vers l'origine et l'angle mesuré à 18 degrés.

- Une table avec n attributs numériques (par exemple, nombre de pixels à dominante verte) peut être tracée comme des points dans un espace à n dimensions.
- L'emplacement de ces points dans l'espace peut être utilisé pour calculer différentes mesures de similarité (égalité, distance, angle, etc.).
- Les ingénieurs en apprentissage automatique utilisent généralement la mesure d'angle, car elle reflète mieux l'intuition humaine.

Point clé

Si les données d'entrée ne sont *pas* numériques, nous pouvons calculer des nombres quand même !

- Dans notre *fichier Images Similaires*, nous avons généré des attributs numériques comme SYMMETRY, LUMINANCE, et ENTROPY.
- Nous avons aussi généré de très longues chaînes de COLOR-NAMES, listant chaque couleur primaire dominante dans l'ordre des pixels.
- Pour chaque image, nous avons transformé notre chaîne ordonnée de couleurs en un modèle sac de mots : un compte *non ordonné* du nombre de pixels à dominante red, green, et blue, nous permettant de tracer des images dans un « espace des couleurs » à 3 dimensions.

Activité

- Ouvrez le **fichier Langage Naturel** (Langage-Naturel-Starter.arr), enregistrez une copie, et cliquez sur « Run ».
- Trouvez les lignes 25–39 de la Zone de Définitions, qui définissent notre table corpus initiale.



FIGURE 2 – Un plan avec deux points (2, 2) et (6, 1). Le triangle rectangle avec son hypoténuse entre ces points est dessiné en gris.

Point clé

Rappelez-vous notre fonction de similarité d'angle :

```
# angle-similarity :: (Table t, String id,
List<String> colonnes) -> Table
```

Nous voulons lui demander de trouver des correspondances pour un essai particulier, et lui indiquer quels attributs nous intéressent.

Réflexion

- Pourquoi ne pouvons-nous pas utiliser **angle-similarity** avec notre **corpus**, tel quel ?
 - Elle ne contient aucune colonne quantitative !

Activité

- Les lignes 3–23 de la Zone de Définitions définissent une série de courts textes sur des animaux, en français.
- Trouvez `mystere` à la ligne 23 et lisez le texte.

Réflexion

- Lequel des autres documents vous attendez-vous à être le plus similaire à **mystere** ? Pourquoi ?
 - `elephant`, parce que les deux documents parlent d'éléphants.
- En tant qu'humain, qu'est-ce qui vous dit de quoi un essai « parle » ?
 - le titre, la phrase d'introduction, un mot qui revient souvent...
 - je le sais juste en lisant...

Exploration : attributs quantitatifs du texte

Réflexion

Comme nous le savons, Pyret ne comprend rien à ce que ces documents *signifient*. Mais il *peut* calculer divers attributs à partir des documents, et comparer leur similarité en utilisant des angles ou des distances.

- **Quelles idées avez-vous pour des colonnes quantitatives que Pyret pourrait calculer sur ces documents ?**

Notez une liste au tableau. Les réponses possibles incluent :

- Nombre de mots
- Nombre de phrases
- Nombre moyen de mots par phrase
- Longueur moyenne des mots utilisés
- Nombre de syllabes dans le document
- Nombre moyen de syllabes par mot
- Sac de mots → le nombre de fois où chaque mot apparaît
- **Lequel des attributs de notre liste ferait le meilleur travail pour décider quel document est le plus similaire à *mystere* ?**
- **Lequel des attributs de notre liste sont des choses auxquelles vous avez pensé en décidant quel texte était le plus similaire à notre texte *mystere* ?**
 - Probablement aucun.
- **En repensant à la façon dont vous avez décidé quel texte était le plus similaire, avez-vous d'autres idées pour des colonnes que Pyret pourrait calculer ?**

Point clé

Pyret possède un certain nombre de fonctions qui calculent des nombres décrivant différentes caractéristiques du texte :

```
# string-length :: String -> Number
# num-words :: String -> Number
# num-syllables :: String -> Number
# num-sentences :: String -> Number
# text-grade :: String -> Number
```

Activité

- Retournez à votre fichier **Langage Naturel**.
- Évaluez `decorated` pour voir une table avec des colonnes générées par ces fonctions.
- **Que remarquez-vous ? Que vous demandez-vous ?**

Réflexion

- **Combien de dimensions Pyret pourrait-il calculer pour la similarité en utilisant cette table? Comment le savez-vous?**
 - 5 dimensions. Il y a 5 colonnes quantitatives.

Point clé

Nous pouvons utiliser `angle-similarity`, `image-scatter-plot` et `image-dot-plot` pour explorer les relations dans nos nouvelles colonnes. Pyret possède aussi une autre fonction de similarité qui *utilise toutes les colonnes numériques* pour calculer la similarité d'angle par rapport à une ligne donnée :

```
# all-cols-similarity :: (Table t, String id) ->
Table
```

Par exemple : `all-cols-similarity(decorated, "?")` trouvera la similarité d'angle de chaque document par rapport à notre ligne mystère "?", en utilisant chaque colonne contenant des nombres dans notre table `decorated`.

Activité

Prenez un moment pour expérimenter avec nos nouvelles colonnes en utilisant les fonctions suivantes :

- `all-cols-similarity`
- `angle-similarity`
- `image-scatter-plot`
- `image-dot-plot`

Quelle est l'utilité de ces colonnes pour identifier quels textes sont les plus similaires à ??

Notes pour l'enseignant·e

Ne passez pas trop de temps là-dessus car ces colonnes ne sont PAS très utiles!

Réflexion

- **Avez-vous trouvé des comparaisons qui auraient aidé à déterminer quel texte était le plus similaire à *mystere*?**
 - Probablement pas.
- **Une des colonnes que Pyret a calculées capte-t-elle ce dont un essai *parle*?**
 - Le nombre de caractères, de mots, de syllabes et de phrases ne nous dit rien sur le *sujet* d'un essai.
 - Nous avons besoin d'informations sur *quels* mots sont utilisés pour apprendre le *sujet* d'un essai.
 - Avec notre exemple d'images, *luminance* et *entropy* nous disaient au moins *quelque chose* sur l'apparence de l'image. Imaginez si nous avions essayé de comparer nos images de montagnes en utilisant seulement leur largeur et leur hauteur !

Point clé

Notre meilleur outil pour comparer le contenu réel des textes est de calculer leur sac de mots.
Évaluez `computed` pour voir une table avec des colonnes représentant les comptes pour chaque mot.

Réflexion

- **Que remarquez-vous? Que vous demandez-vous?**

Prenez le temps de laisser les élèves faire émerger beaucoup d'observations ! Celles-ci peuvent inclure :

- Beaucoup de mots n'apparaissent qu'une seule fois dans un seul essai !
- Il n'y a pas beaucoup de chevauchement entre les mots utilisés.
- Il y a certains mots qui apparaissent dans presque chaque essai.
- Certains mots sont en réalité des nombres.
- Certains mots sont listés avec de la ponctuation comme des virgules et des points.
- À moins que les mots soient exactement les mêmes, ils sont comptés séparément, par exemple `adult`, `adulthood`.

Réflexion

- **Pourquoi ce sac de mots pourrait-il s'avérer moins utile que ceux que nous avons utilisés pour définir l'espace des couleurs de nos images ?**
 - Il y a beaucoup de colonnes dans la table `computed` ! Et la plupart ont soit des valeurs similaires dans chaque ligne, soit aucune valeur qui se chevauche !
 - Quand nous avons calculé un sac de mots pour nos images, il n'y avait que 3 colonnes et elles étaient pertinentes pour chaque image.
- **Si notre table `computed` a 365 colonnes *au total*, combien de dimensions notre modèle sac de mots `computed` a-t-il ?**
 - 360, parce que 5 de nos colonnes ne sont pas quantitatives.

Synthèse

Réflexion

- **Quelles sont les limites de nos fonctions de calcul de similarité appliquées au texte ?**
 - Elles ne peuvent travailler qu'avec des colonnes quantitatives.
 - Toutes les colonnes quantitatives ne nous en disent pas beaucoup sur la similarité de deux textes.

Normalisation des données

Objectif de la section

Les élèves explorent l'importance de la normalisation des données, quand nous organisons les données pour suivre un modèle standard.

Lancement

Maintenant que nous utilisons un modèle sac de mots pour du texte plus complexe que nos longues listes de pixels `red`, `blue`, et `green`, nous nous retrouvons avec *beaucoup* de colonnes, dont beaucoup ne contiennent pas d'information utile.

Activité

Prenons un moment pour considérer **ce que les humains savent du texte que les machines ne savent pas**.

Complétez la première section de *Normaliser du texte*.

Réflexion

- **Pourquoi Pyret n'a-t-il pas identifié le même nombre de références à « blaireau » dans le texte que vous ?**
 - Nos données sont « sales » :
 - Ponctuation : `blaireau`, et `blaireau.` ne sont pas deux mots différents, mais le système les compte séparément à cause de la virgule et du point.
 - Majuscules : `Le` et `le` ne sont pas deux mots différents, mais le système les distingue à cause de la majuscule.
- **Quels mots suggèreriez-vous que Pyret ignore lors de la recherche de similarité entre documents ?**
 - `le`, `la`, `les`, `un`, `une`, `et`, `de`, `en`, `est`, `qui`, `que`...
- **Quelles idées avez-vous pour améliorer la capacité de Pyret à reconnaître les mots identiques comme identiques ?**

Point clé

Normalisation des données

Nos données sont « sales ». Des **majuscules** et de la **punctuation** inconsistantes empêchent l'ordinateur de reconnaître le même mot chaque fois qu'il est utilisé. En conséquence :

1. Nos comptes pour ces mots sont faux, donc nous ne voyons pas à quel point ils sont vraiment communs.
2. Nous créons des dimensions supplémentaires sans signification dans lesquelles le texte est comparé !

La présence quasi-universelle de mots comme « le », « la », « les », « et », « de », « est », etc. (connus sous le nom de **stop words** ou *mots vides*) dans chaque essai est aussi un problème :

1. Cela crée de nombreuses dimensions dans lesquelles les essais sont proches.
2. Ces dimensions augmentent le score de similarité entre deux essais simplement parce qu'ils sont tous deux en français !

S'attaquer à cette « saleté » s'appelle la **normalisation des données**.

Exploration : trois fonctions de normalisation

Point clé

Les ingénieur-es en apprentissage automatique et les data scientists se soucient beaucoup de normaliser leurs données afin de couper le bruit non pertinent et de se concentrer sur ce qui compte. Nous avons fourni trois fonctions de normalisation pour que vous expérimentiez :

```
# lowercase :: String -> String
# remove-punct-fr :: String -> String
# remove-stop-words-fr :: String -> String
```

Activité

Complétez la deuxième section de *Normaliser du texte* pour explorer ce que fait chacune de ces fonctions.

Réflexion

— Que remarquez-vous ? Que vous demandez-vous ?

Les réponses varieront, mais peuvent inclure :

- Le texte devient beaucoup plus court.
- Le texte n'a pas totalement de sens après normalisation.
- La fonction `remove-punct-fr` remplace les apostrophes par des espaces (ainsi `l'éléphant` devient `l éléphant`), ce qui permet de séparer les articles élidés.
- Nous n'avons pas de fonction pour supprimer les pluriels.

Point clé

Adaptation française des fonctions de normalisation

Dans l'original anglais, la bibliothèque `ai-library.arr` de Bootstrap fournit une liste de *stop words* anglais (« the », « and », « a », etc.) et des fonctions de normalisation adaptées à l'anglais. Notre fichier de démarrage français **redéfinit** trois éléments :

1. `stop-words` — remplacé par une liste de mots vides français (« le », « la », « les », « un », « et », « de », « est », etc.).
2. `remove-punct-fr` — nouvelle fonction qui *préserve les accents français* (é, è, ê, à, ç, ù, etc.). La fonction originale de la bibliothèque supprimait tous les caractères en dehors de `a-z`, ce qui aurait détruit les accents !
3. `remove-stop-words-fr` et `normalize-text-table-fr` — utilisent la liste française et la nouvelle fonction de ponctuation.

C'est la seule modification du code nécessaire pour adapter cette leçon au français.

Activité

Voyons si Pyret peut identifier quel document est le plus similaire à ?.
Complétez la dernière section de *Normaliser du texte*.

Réflexion

- Avant que nous normalisions nos données, Pyret a-t-il calculé **elephant** comme le texte le plus similaire à **mystere**?
 - Oui.
- Avant la normalisation, Pyret a-t-il calculé d'autres textes comme étant quelque peu similaires à **mystere**?
- Comment cela se compare-t-il aux calculs de similarité après normalisation?
- Expliquez pourquoi la normalisation a changé les résultats?
 - La suppression des données inutiles et des mots courants nous a permis de concentrer notre comparaison sur seulement les mots qui comptent, et de les compter correctement.
- Quel modèle sac de mots avait le plus de dimensions, celui pour **computed** ou pour **norm-computed**?
 - **computed**. Notre modèle **norm-computed** devrait avoir beaucoup moins de colonnes!
- Vous attendriez-vous à ce qu'un modèle sac de mots construit avec 1000 colonnes ou 200 colonnes soit meilleur?
 - Ça dépend! Le nombre de colonnes de données disponibles n'est pas un bon moyen de déterminer la qualité d'un modèle sac de mots!

Synthèse

Réflexion

- **Que signifie normaliser du texte ?**
 - Le standardiser pour réduire les redondances et le bruit.
 - Objectif 1 : s'assurer que chaque occurrence d'un mot finit par être comptée comme le même mot.
 - Objectif 2 : supprimer les stop words pour qu'ils ne conduisent pas à des faux calculs de similarité.
- **À quoi ressemblerait la normalisation de données impliquant des adresses ?**
 - Standardiser la façon dont les noms sont écrits pour ne pas se retrouver avec des entrées séparées pour Rue, St. et Saint.
- **À quoi ressemblerait la normalisation de données sur les niveaux de classe ?**
 - Standardiser pour que « sixième », « 6^e » et « 6 » ne soient pas tous enregistrés séparément.
- **À quoi ressemblerait la normalisation de données sur les numéros de téléphone ?**
 - Standardiser le nombre de chiffres et le formatage attendu. Voulons-nous commencer par l'indicatif pays ? Voulons-nous utiliser des espaces, des tirets, ou rien ?
- **À quoi ressemblerait la normalisation de données sur la taille des personnes ?**
 - Standardiser les unités : voulons-nous 1 m 72 ou 172 cm ?

Similarité supervisée et non supervisée du langage

Objectif de la section

Forts de leur détection de similarité, les élèves explorent comment cet algorithme peut être utilisé pour détecter le plagiat et effectuer une analyse de sentiment. Maintenant qu'ils savent comment il fonctionne, ils considèrent les limites de l'algorithme et quand il pourrait ne pas être éthique pour les enseignant·es d'utiliser ces modèles pour la détection de plagiat, ou quand l'utiliser pour vérifier le ton de leurs courriels.

Lancement

Point clé

Un **corpus d'entraînement** est une collection de données utilisée pour entraîner des modèles d'IA/ML, leur permettant d'apprendre des motifs et de faire des prédictions.

Considérons une application non supervisée...

- Quand pourrions-nous vouloir savoir si deux essais sont similaires ?
- Quand un·e *enseignant·e* pourrait-iel vouloir savoir si deux essais sont similaires ?

Considérons une application supervisée...

- Pourquoi pourrait-il être utile d'avoir des centroïdes pour des courriels avec beaucoup de « mots en colère » ? Avec des « mots amicaux » ?
- Pourquoi pourrait-il être utile d'avoir des centroïdes pour des centaines de sujets différents ?

Réflexion

Pour un détecteur de plagiat, le corpus est l'ensemble des documents précédemment fournis au détecteur.

- **Quels types de documents composent le corpus d'entraînement d'un détecteur de plagiat efficace ? Listez-en autant que possible.**
 - Le corpus inclurait probablement :
 - les essais écrits et soumis par les élèves actuellement dans la classe
 - les essais écrits et soumis par les élèves précédemment dans la classe
 - les articles Wikipédia
 - les articles sur des sujets pertinents disponibles sur Internet, etc.

Point clé

Supposons qu'une enseignante construise un détecteur de plagiat pour de courts essais sur des animaux. Elle transforme des paragraphes pour dix animaux différents en sacs de mots et les ajoute au modèle. Cette configuration est faite une seule fois, et peut être réutilisée pour toute soumission d'élève.

La phase d'entraînement est l'endroit où l'énorme corpus d'essais, d'articles Wikipédia, etc. est converti en sac de mots pour chaque document, et stocké.

Notre table `bags` est notre modèle!

Exploration : détecter le plagiat

Point clé

Une fois qu'un modèle est entraîné, le corpus peut être interrogé autant de fois que nous le voulons sans avoir à répéter le travail fait pendant l'entraînement!

Pour attraper le plagiat dans *n'importe quel* essai, une enseignante a besoin d'un modèle entraîné sur une collection de documents *massive*. Le traitement de ce grand corpus crée un espace complexe et de haute dimension où chaque mot unique ajoute une nouvelle dimension.

Réflexion

- **Si une enseignante fournit vingt essais d'élèves de 500 mots à un détecteur de plagiat comme corpus d'entraînement, combien de dimensions le modèle résultant aura-t-il environ?**

Les élèves devraient fournir une large gamme d'estimations.

- La plus grande estimation possible serait 10 000 dimensions (20 essais $\times$ 500 mots)
 - mais ce n'est pas une bonne estimation, car nous répétons et réutilisons couramment des mots comme « le », « et », « un », etc.
- Avant de faire une estimation, les élèves pourraient avoir des questions de clarification, comme :
 - Tous les élèves ont-ils écrit sur le même sujet?
 - Quel est le niveau de sophistication de l'écriture des élèves?
 - Tous les élèves ont-ils réellement écrit 500 mots?
- Une prédiction raisonnable serait qu'il y aurait au moins quelques centaines de dimensions dans le modèle.

Activité

Complétez *Détecter le plagiat avec la similarité*.

Réflexion

- Quels mots apparaîtraient dans un centroïde pour « mots en colère » ?
- Quels mots apparaîtraient dans un centroïde pour « mots amicaux » ?
- Quels mots apparaîtraient dans un centroïde pour « mots professionnels » ?
- Comment Grammarly vérifie-t-il si le courriel à votre patron va vous attirer des ennuis ?

Point clé

En ajoutant l'apprentissage supervisé à notre boîte à outils, nous pouvons commencer à effectuer ce que les ingénier·es ML appellent l'**analyse de sentiment** sur le *ton* ou le *sujet* de nos courriels et SMS !

- Cela permet à l'algorithme de vérifier si notre courriel est « amical » ou « en colère ».
- Cela permet à notre téléphone de résumer tous les textos reçus de notre ami·e en une notification concise.

Synthèse : éthique des détecteurs de plagiat

Réflexion

- Dans la classe A, des élèves de 6^e doivent écrire des essais d'un paragraphe sur les zèbres.
- Dans la classe B, des lycéen·nes doivent écrire un devoir de 3 pages sur leur série préférée.

Sachant ce que vous savez sur le fonctionnement des détecteurs de plagiat, pourquoi s'attendrait-on à ce que le détecteur de plagiat accuse plus d'élèves dans la classe A que dans la classe B ?

- Tous les essais portent sur les zèbres, donc le nombre de mots uniques sera petit (ils utiliseront tous « zèbre », « rayures », et « Afrique », par exemple).
- N'ayant qu'un paragraphe de long, il n'y a pas beaucoup de place pour que la fréquence des mots diffère ! Il est très probable qu'il y aura des faux positifs dans la classe A, et un détecteur de plagiat n'est tout simplement pas approprié.
- Les élèves de 6^e ont des vocabulaires plus petits que les lycéen·nes, donc leurs essais auront plus de mots en commun peu importe le sujet.

Annexe A : Stop words français

Le fichier de démarrage `Langage-Naturel-Starter.arr` redéfinit la liste des stop words avec une liste française standard, et fournit une version française de toutes les fonctions de normalisation qui préservent les accents. Voici quelques-uns des mots les plus courants qui sont supprimés lors de la normalisation :

Articles	Pronoms	Prépositions	Conjonctions & autres
le, la, les	je, tu, il, elle	de, en, dans	et, ou, mais
un, une, des	nous, vous, ils	sur, sous, avec	donc, or, ni, car
du, de, d	on, me, te, se	sans, pour, par	que, qui, quoi
au, aux	mon, ma, mes	vers, chez, entre	ne, pas, plus
ce, cet, cette	ton, ta, tes	hors, parmi	aussi, très, bien

La liste complète (environ 100 mots) est définie dans le fichier de démarrage. Elle inclut également les formes verbales courantes (« est », « sont », « était », « ont », « eu », « été ») et les pronoms démonstratifs (« ceci », « cela », « celui », « celle »).

Annexe B : Fichiers du projet

Fichier	Description
<code>Langage-Naturel-Starter.arr</code>	Fichier de démarrage Pyret : charge <code>ai-library.arr</code> depuis <code>Bootstrap</code> . Redéfinit <code>stop-words</code> avec une liste française, ajoute <code>remove-punct-fr</code> (préserve les accents), et <code>remove-stop-words-fr</code> / <code>normalize-text-table-fr</code> . Textes d'animaux traduits en français.
<code>traitement-langage-naturel.tex</code> <code>images/</code>	Document de cours (ce fichier) 3 images : système de coordonnées 3D, triangle rectangle, CCbadge

À noter : contrairement à la leçon originale anglaise où les stop words et les fonctions de normalisation sont définis dans la bibliothèque `Bootstrap`, notre adaptation française redéfinit `stop-words` (avec `shadow`) et ajoute `remove-punct-fr`, `remove-stop-words-fr` et `normalize-text-table-fr` directement dans le fichier de démarrage. La fonction `remove-punct-fr` est *indispensable* pour le français : la fonction originale de la bibliothèque supprime tous les caractères en dehors de `a-z/A-Z`, ce qui détruit les accents (é, è, ê, à, ç, etc.). Notre version préserve les accents et remplace les apostrophes par des espaces. Toutes les autres fonctions de la bibliothèque fonctionnent inchangées.

À propos de ces supports

Ces supports ont été développés en partie grâce au soutien de la *National Science Foundation* (bourses 1042210, 1535276, 1648684, 1738598, 2031479 et 1501927).

Bootstrap par la Communauté Bootstrap est sous licence Creative Commons 4.0 Unported. Cette licence n'accorde pas la permission d'organiser des formations ou du développement professionnel.

Traduction et adaptation française réalisées en juillet 2026.

Source originale : <https://www.bootstrapworld.org/materials/fall2026/en-us/lessons/natural-language/>