

# Modèles de régression simples

Voitures autonomes, apprentissage supervisé et régression linéaire

Traduit et adapté depuis Bootstrap World (Fall 2026)

Licence Creative Commons 4.0 International

*Ces supports ont été développés en partie grâce au soutien de la National Science Foundation  
(bourses 1042210, 1535276, 1648684, 1738598, 2031479 et 1501927).*

# Table des matières

---

|          |                                                        |           |
|----------|--------------------------------------------------------|-----------|
| <b>1</b> | <b>Voitures autonomes</b>                              | <b>3</b>  |
| 1.1      | Lancement . . . . .                                    | 3         |
| 1.1.1    | L'entraînement d'une voiture autonome . . . . .        | 4         |
| 1.2      | Exploration : le simulateur de conduite . . . . .      | 5         |
| 1.3      | Synthèse . . . . .                                     | 7         |
| <b>2</b> | <b>Prédire l'angle de braquage</b>                     | <b>8</b>  |
| 2.1      | Lancement . . . . .                                    | 8         |
| 2.1.1    | Les quatre variables candidates . . . . .              | 9         |
| 2.2      | Exploration : nuages de points . . . . .               | 10        |
| 2.3      | Synthèse . . . . .                                     | 12        |
| <b>3</b> | <b>Régression linéaire</b>                             | <b>13</b> |
| 3.1      | Lancement . . . . .                                    | 13        |
| 3.2      | Exploration : la fonction <code>drive</code> . . . . . | 15        |
| 3.3      | Synthèse . . . . .                                     | 18        |

# Voitures autonomes

## Objectif de la section

Les élèves réfléchissent aux voitures autonomes comme exemple convaincant d'apprentissage automatique supervisé. Ils explorent un simulateur de conduite, collectent leurs propres données d'entraînement, et découvrent que prédire l'angle de braquage est un problème de régression.

## Lancement



FIGURE 1 – Une voiture autonome avec un capteur sur le toit, garée au milieu d'une route vide.

Les voitures autonomes donnent l'impression que le futur est vraiment arrivé ! Beaucoup de gens pensent qu'elles sont l'un des meilleurs exemples d'« IA » qui pense vraiment, au lieu de « suivre un algorithme ». Après tout, *comment un ordinateur peut-il prendre des décisions sur la façon de conduire ?*

Laissez les élèves discuter. Rappelez-leur l'effet IA, et comment les gens ressentaient la même chose quand les premiers correcteurs orthographiques ont été développés !

## Point clé

Les voitures autonomes fonctionnent grâce à de nombreuses entrées (capteurs, caméras, etc.) et de nombreuses sorties (combien accélérer, freiner, braquer). Le braquage, par exemple, est extrêmement difficile ! Les considérations incluent :

- Si la route devant tourne à gauche ou à droite, et avec quelle netteté.
- La distance de la voiture par rapport au centre de la voie.
- Si la voiture est alignée avec la voie ou se dirige vers un côté.
- Les obstacles et feux de circulation qui pourraient se trouver sur le chemin.
- Et bien plus encore !

Nous allons explorer comment une forme d'apprentissage supervisé — la **régression**, plus précisément — permet aux voitures de « savoir où elles vont ».

## L'entraînement d'une voiture autonome

Enseigner à une IA ce que signifie braquer nécessite un **entraînement**. Voici en quoi il consiste :

1. **Une personne conduit le véhicule.**

- Dans l'apprentissage supervisé, le conducteur humain est souvent appelé le *superviseur*.
- Le superviseur démontre le comportement correct (par exemple, dans quelle direction tourner le volant).

2. **Plusieurs fois par seconde, un ordinateur enregistre...**

- les informations de nombreux capteurs autour de la voiture ;
- la direction de braquage choisie par le conducteur à cet instant.

3. **Les données d'entraînement (le corpus d'entraînement) sont représentées comme une table entrée-sortie**, avec des colonnes pour les données des capteurs (entrées) et les angles de braquage corrects (sorties). Par exemple :

| curve | speed | steering-angle |
|-------|-------|----------------|
| 1°    | 45    | 0,02°          |
| 4°    | 21    | 55,20°         |
| -2°   | 56    | -25,43°        |

4. **Le jeu de données sert à générer une fonction.**

- La fonction prédit l'angle de braquage à partir des données des capteurs. Dans la table ci-dessus, *curve* et *speed* sont les variables explicatives ; *steering-angle* est la variable de réponse.

5. **Une fois l'entraînement terminé, un humain appuie sur le bouton « run » et le véhicule commence à conduire!** Au fur et à mesure que la voiture roule, elle évalue continuellement sa fonction apprise pour produire des angles de braquage — tout comme le conducteur humain le faisait pendant l'entraînement.

### Notes pour l'enseignant·e

Si vous voulez montrer à vos élèves un exemple de voiture autonome précoce (1989!), c'est le bon moment pour visionner cette courte vidéo de deux minutes du Robotics Institute de Carnegie Mellon University.

**Réflexion**

- **Quelles autres entrées de capteur pourraient nous aider à déterminer l'angle de braquage souhaité ?**
  - Dans quelle voie nous sommes, si la voiture est alignée avec la route, les obstacles sur notre chemin...
- **L'apprentissage supervisé implique qu'un ordinateur apprend de quelque chose. De quoi l'ordinateur apprend-il, dans notre exemple ?**
  - D'un conducteur humain — le superviseur — qui a démontré le braquage correct.
  - Ces paires entrée-sortie forment le corpus d'entraînement.
- **Pourquoi le modèle résultant est-il une *fonction* ?**
  - Pour le même ensemble d'entrées (données des capteurs), le modèle doit toujours prédire la même sortie (angle de braquage).
- **Pourquoi appelle-t-on cela de l'apprentissage *supervisé* ?**
  - Parce qu'un humain a fourni les bonnes réponses (angles de braquage) pendant l'entraînement, « supervisant » ce que la machine a appris.

**Point clé****Les trois phases de l'apprentissage supervisé**

1. Des données étiquetées par des humains sont enregistrées, démontrant les connaissances à apprendre.
2. Un algorithme d'apprentissage automatique trouve une **fonction** qui fait correspondre les entrées aux sorties correctes (la « clé de réponses »).
3. La fonction apprise peut être appliquée à de nouvelles données, jamais vues auparavant.

## Exploration : le simulateur de conduite

**Activité**

- Ouvrez le fichier **Voiture Autonome — Fichier de Démarrage** (Voiture-Autonome-Starter.arr) et enregistrez une copie. Cliquez sur « Run ».
- Tournez-vous vers *Explorer le simulateur de conduite* et suivez les instructions.

Laissez les élèves jouer avec le simulateur pendant plusieurs minutes avant de débriefer. Les élèves qui terminent tôt peuvent essayer de collecter des données à différentes vitesses, ou conduire délibérément mal pour voir à quoi ressemble de mauvaises données d'entraînement.

**Réflexion**

- **Quelles colonnes avez-vous vues dans votre table de données d'entraînement?**
  - speed, curve, skew, offset, et steering-angle
- **Quelle est la différence entre un **steering-angle** positif et négatif?**
  - Positif = tourner à droite. Négatif = tourner à gauche.
  - (Cela pourrait être l'inverse pour d'autres simulateurs, selon la convention.)
- **Combien de lignes de données avez-vous collectées en quelques minutes de conduite?**
  - probablement 500 à 1000.
- **Entraîner un modèle de conduite nécessite les meilleures données possibles. Pensez-vous que vous ou quelqu'un d'autre pourriez mieux conduire la voiture sur la piste avec plus de pratique?**
  - Probablement!

### Notes pour l'enseignant·e

Nous avons préparé pour vous un corpus d'entraînement contenant des données de conduite expertes, collectées sur différentes conditions routières et vitesses de conduite. Il est déjà chargé dans le fichier de démarrage sous le nom `training`.

#### D'où vient **training**?

Ce jeu de données a commencé comme des données réelles d'une course très lente et prudente sur plusieurs pistes. La taille initiale était un peu plus de 10 000 lignes, assemblées à partir de passages « idéaux » séparés sur plusieurs pistes. Les données brutes combinées ont ensuite été *post-traitées* via une moyenne mobile, qui lisse les valeurs extrêmes en quelque chose de beaucoup plus naturel. Une autre étape de post-traitement a impliqué la suppression des valeurs aberrantes les plus sévères, en utilisant la connaissance de la piste (un `skew` supérieur à 80°, par exemple, représente de toute évidence une erreur humaine!).

Nous avons même fourni une API pour que vos élèves puissent faire une partie de ce post-traitement eux-mêmes :

```
# trim :: (Table t, String col, Number lo, Number
hi) -> Table
# Étant donné une colonne, supprime toutes les
lignes où la valeur dans cette colonne est en
dehors de l'intervalle [lo, hi]
```

```
# sample-rows :: (Table t, Number every-n) ->
Table
# Étant donné une table, ne garde qu'une ligne
sur n (utile pour ce jeu de données, où 5 lignes
consécutives sont si proches dans le temps que les
données supplémentaires ne sont que du bruit)
```

Est-ce de la « triche » ? Pas du tout ! En fait, c'est un excellent point de discussion si vos élèves le demandent. L'apprentissage automatique dépend tellement de la qualité des données que des efforts énormes sont consacrés à trouver des moyens d'améliorer cette qualité par toutes les méthodes disponibles, avant qu'un modèle ne soit entraîné.

## Synthèse

### Réflexion

- Pourquoi qualifie-t-on le processus d'entraînement d'une voiture autonome d'apprentissage supervisé ?
  - Parce que la colonne cible de notre jeu de données est un enregistrement de ce que les humains feraient en recevant les valeurs des autres colonnes.

# Prédire l'angle de braquage

## Objectif de la section

Les élèves identifient les variables explicatives candidates du corpus d'entraînement, créent des nuages de points pour explorer la relation entre chaque variable et `steering-angle`, et choisissent `curve` comme meilleur prédicteur unique.

## Lancement





Dans la leçon *Ajuster des modèles*, nous avons appris qu'une relation entre deux variables apparaît comme un nuage de points dans un diagramme de dispersion, et que nous pouvons décrire cette relation avec un modèle.

### Point clé

- La **variable explicative** (axe des  $x$ ) est l'entrée à partir de laquelle nous prédisons.
- La **variable de réponse** (axe des  $y$ ) est ce que nous essayons de prédire.

Dans notre cas, la variable de réponse est `steering-angle` : le nombre de degrés de rotation du volant. Les données d'entraînement ont plusieurs colonnes qui pourraient servir de variable explicative.

## Les quatre variables candidates

| Variable | Description                                                                                                                                                                                                                                                                                                                                                                                                                     |
|----------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| curve    |  <p>The diagram shows a road curving to the right. A series of yellow dots along the road's edge are labeled with angles: 0°, 1°, 3°, 3°, 2°, 1°, 1°, 0°, 0°, 0°. These angles represent the curvature of the road at different points.</p> <p>La courbure de la route devant la voiture</p>                                                   |
| speed    |  <p>The diagram shows two blue cars on a road. The car in front is labeled with the value 2.9, and the car behind is labeled with the value 1.25. These values represent the speed of the cars.</p> <p>La vitesse à laquelle la voiture se déplace</p>                                                                                        |
| offset   |  <p>The diagram shows three blue cars on a road. The car in the middle is labeled with the value 0.0, the car in front is labeled with +0.5, and the car behind is labeled with -0.5. These values represent the distance of the cars from the center line of the road.</p> <p>La distance de la voiture par rapport à la ligne centrale</p> |
| skew     |  <p>The diagram shows three blue cars on a road. The car in the middle is labeled with the value 0°, the car in front is labeled with +45°, and the car behind is labeled with -90°. These values represent the angle of the cars relative to the road.</p> <p>L'angle de la voiture par rapport à la route</p>                              |

**Réflexion**

- **Laquelle de ces variables pensez-vous être le meilleur prédicteur de l'angle de braquage, et pourquoi?**
  - Les réponses varieront — c'est destiné à stimuler la discussion et faire émerger les intuitions avant que les données ne parlent.

**Réflexion**

- **Quelle visualisation de données fonctionne le mieux pour montrer les relations possibles entre deux variables quantitatives?**
  - Les nuages de points (*scatter plots*).
- **Que devons-nous chercher dans nos visualisations pour choisir la meilleure variable explicative?**
  - La relation la plus forte (points le plus étroitement regroupés autour d'une droite).

## Exploration : nuages de points

**Activité**

- Retournez au fichier **Voiture Autonome**.
- Utilisez *scatter-plot* pour comparer chacune des quatre colonnes explicatives possibles à *steering-angle*.
- Puis complétez *Qu'est-ce qui prédit l'angle de braquage ?*.

**Notes pour l'enseignant·e**

Circulez et encouragez les élèves à lire les nuages de points de façon critique. Poussez-les à remarquer si la relation paraît linéaire, l'importance de la dispersion, et s'il y a des valeurs aberrantes évidentes.




FIGURE 2 – Nuage de points de `steering-angle` en fonction de `curve`, montrant une relation linéaire positive.

### Réflexion

- **Quelle variable a montré la relation la plus forte avec `steering-angle`?**
  - `curve` a une relation claire, presque linéaire. Plus la route tourne fortement dans une direction, plus l'angle de braquage augmente proportionnellement.
- **Quelle variable a montré la relation la plus faible?**
  - `speed` – il y a beaucoup de dispersion sans motif linéaire clair.
- **Une des relations vous a-t-elle surpris?**
  - Les réponses varieront.

### Notes pour l'enseignant·e

Si les élèves remarquent que le nuage de points pour `offset` a une image presque miroir du nuage de `curve` et pensent que c'est un prédicteur aussi bon : attirez leur attention sur le fait que les plages des axes  $x$  pour `curve` et `offset` sont assez différentes. Réinitialisez la fenêtre du nuage de points `curve` à  $-30 < x < 30$  (pour correspondre à la fenêtre de `offset`) afin qu'ils puissent voir que les données sont beaucoup plus étroitement regroupées pour `curve`.

Si vous voulez donner à vos élèves plus de pratique avec `fit-model` et l'interprétation des valeurs  $S$ , vous pouvez leur demander de définir les 4 modèles dans le fichier de démarrage et d'évaluer leur ajustement.

## Synthèse

### Réflexion

- **Si vous n’aviez que 2 lignes de données d’entraînement — et qu’elles tombent en ligne droite parfaite — feriez-vous confiance à un modèle construit à partir de ces 2 points ?**
  - Non — deux points peuvent **toujours** être reliés par une droite. Cela ne veut pas dire que le motif est réel ou se généralisera.
- **Combien de données pensez-vous qu’il faudrait avant de pouvoir faire confiance à un modèle ?**
  - Il n’y a pas de réponse unique, mais davantage de données collectées dans une plus grande variété de conditions rendent un modèle plus fiable.
- **La taille du jeu de données est-elle le seul facteur important pour un bon jeu d’entraînement ?**
  - Non — nous avons aussi besoin de données *représentatives* ! Une voiture autonome doit être construite sur des données de toutes sortes de routes, conditions météo, offsets, heures de la journée, tailles de route, vitesses, densité de trafic, etc.

# Régression linéaire

## Objectif de la section

Après avoir ajusté manuellement un modèle linéaire aux données, les élèves utilisent la fonction `lr-plot` de Pyret pour trouver l'ajustement optimal. Ils interprètent les coefficients du modèle et testent leurs prédicteurs avec la fonction `drive`. Enfin, ils réfléchissent à ce que signifie avoir « entraîné » un modèle.

## Lancement

Dans *Qu'est-ce qui prédit l'angle de braquage ?*, vous avez estimé la pente ( $m$ ) et l'ordonnée à l'origine ( $b$ ) des droites que vous avez ajustées aux nuages de points. Mais comment savoir si c'étaient les *meilleurs* modèles linéaires — la droite de meilleur ajustement pour les données ?

## Point clé

Les data scientist-es utilisent une méthode appelée **régression linéaire** pour trouver le motif de droite qui décrit un ensemble d'entrées et une sortie cible déjà connue avec les valeurs *mathématiquement optimales* de  $m$  et  $b$ .

- Cette forme d'apprentissage — où nous connaissons déjà la sortie correcte pour chaque entrée — est appelée **apprentissage supervisé**.
- En apprentissage automatique, l'acte de trouver une fonction à partir des données est appelé **entraînement**.

Les modèles de régression linéaire minimisent l'erreur autant que possible. La fonction `lr-plot` de Pyret calcule et visualise la droite de meilleur ajustement. Son contrat est le même que `scatter-plot` :

```
# lr-plot :: (Table t, String labels, String xs,
String ys) -> Image
```

## Activité

- Utilisez `lr-plot` sur `training` pour trouver la droite de meilleur ajustement pour chacune des variables comparées à `steering-angle`.
- Comment les modèles optimaux de Pyret pour les données se comparent-ils à ceux que vous avez ajustés à la main ?

## Notes pour l'enseignant·e

Les élèves remarqueront que `lm` définit des modèles avec des valeurs décimales, certainement avec une spécificité supérieure à leur modèle dessiné à la main. Cela motive l'idée que l'ordinateur peut optimiser cela bien mieux et plus vite que les humains — ce qui est, après tout, le but de l'apprentissage automatique.




FIGURE 3 – Nuage de points de `steering-angle` en fonction de `curve`, montrant une relation linéaire positive. La droite de meilleur ajustement est superposée au nuage de points.

## Réflexion

- **Que nous dit la pente de notre modèle `curve` ( $\approx 19,5$ )?**
  - Que l'angle de braquage augmente d'environ 19,5 degrés pour chaque augmentation de 1 degré de la courbure.
- **Que nous dit l'ordonnée à l'origine de notre modèle `curve` ( $\approx 0,41$ )?**
  - Si la courbure est nulle, l'angle de braquage devrait être de  $0,41^\circ$ .
- **Est-ce que cela a du sens dans le monde réel?**
  - Presque. Une route avec zéro courbure devrait nécessiter zéro degré de braquage, mais au lieu de cela nous voyons un peu moins d'un demi-degré!
- **Que nous dit la valeur  $S$ ?**
  - Nous nous attendons à ce que l'erreur des prédictions de ce modèle soit de l'ordre de 37 degrés.
  - Cela pourrait expliquer ce mystérieux braquage de  $0,41^\circ$  quand la route est droite!

### Réflexion

- Sur la base de la valeur  $S$ , vous attendez-vous à ce que le modèle **curve** puisse réussir à « conduire » un tour complet de piste?
  - Probablement pas ! 37 degrés est une erreur assez importante.
- Nos fonctions de prédiction s'attendent-elles à ce que l'angle de braquage augmente quand nos autres variables augmentent ?
  - Non ! L'angle de braquage devrait diminuer quand `skew` et `offset` augmentent.
- Comment un modèle de régression est-il « avec perte » (*lossy*) ? Quels détails des données d'entraînement originales perd-il ?
  - Tout ce qui est au-dessus ou en dessous de la droite de régression est une donnée réelle, que nous écartons quand nous utilisons la droite.

### Notes pour l'enseignant·e

Nous ne pouvons pas calculer un  $S$  *significatif* si nous n'avons pas plus de deux lignes dans notre table !

Une droite passant par deux points les ajuste tous les deux parfaitement, donc notre valeur  $S$  est zéro. Mais cela en dit moins sur le modèle que sur le manque de données : il n'y a pas d'erreur à mesurer, donc c'est un « ajustement parfait » sans vraie signification.

## Exploration : la fonction `drive`

Voyons comment nos prédicteurs conduisent la voiture ! Pyret possède une fonction `drive` :

```
# drive :: (predictor :: Row -> Number) -> Table
# fait tourner le simulateur de conduite, en utilisant
# predictor pour calculer l'angle de braquage à chaque
# image
```

### Activité

1. Remarquez que `drive` prend une fonction qui consomme une **Row** — mais `pred-c` consomme un **Number**, pas une **Row** !
2. Pourquoi **`drive`** a-t-il besoin d'une fonction consommant une **Row** plutôt qu'un **Number** ?
  - Parce qu'à chaque instant, `drive` a accès à toute la ligne de données — pas juste une colonne. Une fonction consommant une **Row** peut décider quelles colonnes regarder.
3. Comment pouvons-nous obtenir une version de **`pred-c`** qui consomme une **Row** ?
  - Nous pourrions l'écrire à la main, mais Pyret a exactement l'outil qu'il faut :

```
# regression-model-code :: (Table t, List<String>  
inputs, String prediction) -> Code  
# produit le code qui définit un modèle entraîné  
consommant une Row  
# (à copier/coller dans la Zone de Définitions !)
```

#### Code Pyret

Par exemple :

```
regression-model-code(training, [list: "curve"], "steering-angle  
")
```



FIGURE 4 – ALVINN / Navlab, une ambulance militaire reconvertie en voiture autonome.

**Activité**

- Copiez et collez la définition `curve-predictor` que vous venez de générer dans votre Zone de Définitions et cliquez sur « Run » pour la charger. Puis évaluez `drive(curve-predictor)` dans la Zone d'Interactions.
- Utilisez `regression-model-code` pour générer un prédicteur consommant une Row pour chacune des autres variables.
- Copiez et collez les définitions résultantes de `offset-predictor`, `skew-predictor`, et `speed-predictor` dans votre Zone de Définitions. Cliquez sur « Run ».
- Essayez chacune avec `drive(...)`.
- **Quel prédicteur conduisait le mieux? Cela correspondait-il à vos prédictions des nuages de points?**
  - `curve-predictor` — oui, il avait la relation linéaire la plus forte avec `steering-angle`.
- **Le prédicteur conduisait-il mieux que vous? Pourquoi?**
  - Non!
  - Quand nous conduisions, nous pouvions prendre en compte toutes les variables, alors que le prédicteur n'en utilisait qu'une seule.

**Notes pour l'enseignant·e****Idées fausses courantes****Les données d'entraînement peuvent ne pas être représentatives du monde réel!**

Les élèves peuvent s'attendre à ce qu'un prédicteur construit à partir de bonnes données de braquage conduise parfaitement. Rappelez-leur qu'un modèle ne peut généraliser qu'à partir de ce qu'il a vu — il n'a aucune compréhension de la route. Des données d'une conduite parfaite sur une route droite produiront un modèle qui pourrait très mal s'en sortir sur une route sinueuse!

**Programmation avancée**

Si vous enseignez dans le contexte d'un cours d'informatique, vous pouvez demander aux élèves de trouver comment rendre leur fonction `pred-c` capable de consommer une Row au lieu d'un Number. C'est un excellent exercice sur l'abstraction et la notion de structure de données, utilisant des outils de programmation qu'ils ont vus dans les leçons précédentes.

Si vos objectifs d'apprentissage portent davantage sur la culture IA ou les mathématiques, ce serait un bon défi pour un élève avancé. Sinon, vous pouvez passer à `regression-model-code`, qui écrira le code d'accès aux Row à leur place.

## Synthèse

### Point clé

Félicitations — vous venez d'**entraîner un modèle d'apprentissage automatique** !

- **Que signifiait « entraîner » dans ce contexte ?**
  - Nous avons fourni à l'ordinateur un jeu de données de paires entrée-sortie (*curve* → *steering-angle*), et il a trouvé la fonction qui fait le mieux correspondre entrée et sortie.
- **Supposons que la voiture rencontre une courbe plus forte que toutes celles des données d'entraînement. Que fera le prédicteur ?**
  - Il extrapolera à partir du motif qu'il a appris — ce qui peut ou non être précis. Il n'a aucun moyen de savoir qu'il est en dehors de sa plage d'entraînement.
- **Et si nos données d'entraînement ont toutes été collectées sur des routes sèches, et que la voiture conduit maintenant sur de la glace ?**
  - Le modèle n'a jamais été entraîné sur ces conditions. Il prédira comme si les conditions étaient normales — ce qui pourrait être très faux.

### Réflexion

- **Pourrions-nous entraîner un modèle en utilisant plus d'une variable explicative ?**
  - Oui ! La régression multiple permet de prédire une variable de réponse à partir de plusieurs variables explicatives.
- **À quoi ressemblerait une droite de meilleur ajustement sur un nuage de points avec deux variables explicatives ? Aurions-nous une pente et une ordonnée ? Deux ?**
  - La droite deviendrait un *plan* dans un espace 3D, avec une pente pour chaque variable explicative.

### Point clé

**Les ordinateurs ne sont pas des gens !**

Dans les conversations sur l'IA, les ordinateurs sont souvent *anthropomorphisés* — on leur prête des traits humains alors qu'ils ne sont pas humains. Cela peut empêcher les élèves de comprendre la mécanique de l'apprentissage automatique.

Évitez de dire que le modèle « sait » conduire, ou qu'il « comprend » la route.

Le résultat d'un modèle est toujours le fruit d'une **computation mathématique** — l'évaluation d'une fonction apprise sur une entrée. Tout l'apprentissage automatique supervisé repose sur des données, des fonctions, et des computations.

## Annexe A : Le vocabulaire de l'apprentissage supervisé

| Terme                         | Définition                                                                                                                                     |
|-------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------|
| Apprentissage supervisé       | Forme d'apprentissage où l'algorithme apprend à partir d'exemples étiquetés (entrées avec sorties connues), fournis par un superviseur humain. |
| Corpus d'entraînement         | L'ensemble des données étiquetées utilisées pour entraîner le modèle.                                                                          |
| Entraînement                  | L'acte de trouver une fonction à partir des données d'entraînement.                                                                            |
| Modèle                        | Une fonction qui résume la relation entre les variables d'entrée et de sortie.                                                                 |
| Variable explicative          | L'entrée utilisée pour prédire la sortie (axe des $x$ ). Aussi appelée variable indépendante.                                                  |
| Variable de réponse           | La sortie que nous essayons de prédire (axe des $y$ ). Aussi appelée variable dépendante.                                                      |
| Régression linéaire           | Méthode statistique qui trouve la droite de meilleur ajustement entre une variable explicative et une variable de réponse.                     |
| Droite de meilleur ajustement | La droite qui minimise la somme des résidus au carré.                                                                                          |
| Résidu                        | La différence entre la valeur réelle et la valeur prédite par le modèle, pour un point donné.                                                  |
| $S$ (écart-type des résidus)  | Mesure de la qualité d'ajustement : plus $S$ est petit, meilleur est l'ajustement. Exprimé en unités de la variable de réponse.                |
| Surapprentissage              | Quand un modèle « mémorise » le bruit des données d'entraînement au lieu d'apprendre le motif réel, et échoue sur de nouvelles données.        |

## Annexe B : Fichiers du projet

| Fichier                                                             | Description                                                                                                                                                                                                           |
|---------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <code>Voiture-Autonyme-Starter.arr</code>                           | Fichier de démarrage Pyret : charge <code>self-driving-car-library.arr</code> depuis Bootstrap, fournit <code>training</code> , <code>drive</code> , <code>lr-plot</code> , <code>regression-model-code</code> , etc. |
| <code>modeles-regression-simples.tex</code><br><code>images/</code> | Document de cours (ce fichier)<br>Photos (voiture autonome, ALVINN/Navlab) et diagrammes (courbure, vitesse, offset, skew, nuages de points)                                                                          |

**À noter :** contrairement aux leçons précédentes (arbres de décision, ajustement de modèles), ce fichier de démarrage ne charge pas de données CSV externe. La table `training` est fournie *directement* par la bibliothèque `self-driving-car-library.arr` de Bootstrap. Les noms de colonnes (`steering-angle`, `curve`, `speed`, `skew`, `offset`) sont codés en dur dans la bibliothèque et ne peuvent pas être traduits sans modifier la bibliothèque elle-même (744 lignes). Tous les commentaires et noms de fonctions définis par l'élève sont en français.

## À propos de ces supports

---

Ces supports ont été développés en partie grâce au soutien de la *National Science Foundation* (bourses 1042210, 1535276, 1648684, 1738598, 2031479 et 1501927).

**Bootstrap** par la Communauté Bootstrap est sous licence Creative Commons 4.0 Unported. Cette licence n'accorde pas la permission d'organiser des formations ou du développement professionnel.

*Traduction et adaptation française réalisées en juillet 2026.*

*Source originale : <https://www.bootstrapworld.org/materials/fall2026/en-us/lessons/regression-models-simple/>*